


Role change | TP1 的完整变换图

同一模型 · PP=1 · 每个引擎实例恰好占 1 张 GPU；双向箭头表示一对互逆变换。




A 先固定单位：PD 是服务路径，P、D 分别是实例



B add / delete GPU：增加或减少单卡副本


向右 add；向左 delete



这里的 add/delete 是活动资源增减：当前 controller 唤醒或停驻既有 fleet 实例；外加新卡还需要配置和启动。

C role change 与跨类型 merge / split

GPU 数守恒；每张卡都显示去向



D 逻辑 pool 的 merge / split

改变集合边界；GPU、引擎副本数和 TP 都不变

