


PDblend 当前 Planner：从负载到部署，再到每个请求

源码版本：2026-09-24 工作区 · 默认策略 pdblend · 例子为 synthetic profile 的 CPU 复算

01 三个层次，一条反馈闭环



02 一次规划如何选出方案

固定 TP 的 PoolPlanner 主路径



03 具体例子：第二名为什么赢

8×TP1；18 req/s；输入四种等概率；输出 64

输入 256 / 512 / 2048 / 4096；SLO = 1 s / 20 ms；筛选线 = 850 ms / 17 ms；当前 A = M8 @2520 MHz


$\tau=1024 \Rightarrow \text{M}$: 9 req/s, 平均输入 384；PD: 9 req/s, 平均输入 3072。全枚举得到 40 个可行候选。

候选	配置 / 频率	功率 W	TPOT ms	切换 J	60s kJ
A 当前	M8；M=2520	1016.039	14.976	0.0	60.962
B	M6 + off2；M=2520	894.612	16.326	0.0	53.677
C 稳态最低	P2 D1 M4 off1；M=2100	875.673	15.629	47.6	52.588
D 最终选择	P2 D1 M4 off1；全2520	875.714	14.454	0.0	52.543
F 淘汰	M5 + off3；TPOT超过17	834.150	17.596	0.0	50.049

C 的 60 s 稳态节省仅 2.470 J，却多计 47.6 J 改频成本，D 胜出；D 相对 A 模型收益 13.81% > 8%。

04 计划落卡与负载变化

以下每次重规划均为无 backlog 的说明截面



注意：功率、延迟、收益均为模型预测；旧切换估计的 0 J 不等于真实切换无成本。详细公式、代码位置与复算数据见同目录 README / example.json。